

LLMs in der Fragengenerierung – Zwischenverteidigung –

Malte Grube – B.Sc. Informatik (2021)¹

¹Betreuer: *Prof. Dr. rer.nat.habil. Clemens H. Cap*
Jun.-Prof.in Dr.in Charlott Rubach

30. Juni 2025

- 1. Einführung & Problem**
- 2. Exp. 1 Methodik**
- 3. Ergebnisse & Diskussion**
- 4. Fazit & Ausblick**

Einführung & Problem

Motivation & Problemstellung I

- **Motivation:**
 - ▷ Aktives Lernen → gezielte Fragen
 - ▷ Anspruchsvolle Fragen → zeitaufwendig [Ste+21]
- **Potenzial von LLMs:** Automatisierte Fragen-generierung → bessere Lehrmaterialien-Erstellung + Lernerfahrungen möglich [Nav+24]

Motivation & Problemstellung II

- **Problemstellung:** Qualität oft unklar → mangelnde systematische Evaluation über linguistische Tests hinaus [Hor+20]
 - ▷ Selten pädagogische Bewertung [ZWC25; Blo+23; SCS24]
 - ▷ Mangelnde Performance bei höheren kognitiven Levels [Elk+23; SCS24]
 - ▷ Relevanz $\neq$ Inhaltstreue [Elk+23; HWY24; ML24]
- **Forschungslücken:**
 - ▷ Untersuchung der Inhaltstreue von LLMs
 - ▷ Einhalten kognitiver Anforderungsniveaus

Forschungsfragen

- **RQ1:** Zu welchem Grad **halten sich LLMs** an den Inhalt verschiedener bereitgestellter **Lehrtexte** bei der Generierung von Fragen?
- **RQ2:** Wie beeinflusst die **Beziehung** zwischen verschiedenen Frageformaten und den Levels der Bloom's Taxonomie die **pädagogische Wirksamkeit** von LLM-generierten Fragen?

Bloom's revised Taxonomy

- **Pädagogische Relevanz:** Systematische Bewertung kognitiver Anforderungen von Fragen




Abbildung 1: Kognitive Hierarchie [Kra02].

Herausforderungen der Literatur

- **Veraltete Modelle** – Kein Reasoning
- **Halluzinationen** – Falsche Ausgaben
- **Inhaltstreue** – Forschung nötig
- **Metriken im Fokus** – Quantitative Evaluation
- **Expertenbewertung** – Qualitative Evaluation
- **Bloom's Taxonomy** – Hohe kognitive Levels

Exp. 1 Methodik

Experimentelles Design I

- **Ziel:** Bewertung der Inhaltstreue LLM-generierter Fragen + Qualität
- **Materialien:** 3 Quellen – ISO-OSI-Modell
 - ▷ Script – Prof. Cap's „Referenzarchitekturen“ (DE)
 - ▷ Transcript – Audio-zu-Text (DE)
 - ▷ „Computer Networks“ – Textbook (EN)
- **Exp 1a:** Originaltexte
- **Exp 1b:** Manipuliertes Script

Experimentelles Design II

- 4 Large Language Models:
 - ▷ **DeepSeek R1:** Jan 2025 – manuell
 - ▷ **Claude 3.7 Sonnet:** Feb 2025 – API
 - ▷ **Gemini 2.5 Flash:** Mar 2025 – API
 - ▷ **OpenAI o3:** Apr 2025 – API
- 2 Prompt-Strategien:
 - ▷ **Einfach:** Weniger Anweisungen, keine Strukturierung, aber Formatvorlage + Material
 - ▷ **Komplex:** Rollenzuweisung, detaillierte Anweisungen, fordert nicht-triviales und kritisches Denken, Struktur durch Docstrings, Formatvorlage + Material

Datenerhebung & Durchführung

- **Python:** Automatisierte API-Ansteuerungen
- **Manuell:** DeepSeek R1
- **Material:** Layer-weise Aufteilung
- **Resultat:**
 - ▷ **Exp 1a:** 168 Fragen
 - ▷ **Exp 1b:** 56 Fragen

4 LLMs × 3 Inputs × 7 Layers × 2 Prompts = 168 Fragen

4 LLMs × 1 Input × 7 Layers × 2 Prompts = 56 Fragen

Evaluations-Methodik I

- **Quantitativ:**

- ▷ **Semantic Similarity:** Generierte Frage vs. Originaltext
→ Embedding-Modell & Cosine Similarity

$$\cos(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|}$$

- ▷ **Adherence Score:** o3 & Claude 3.7 Sonnet Prompting

- **Qualitativ:** Prof. Cap + 4 Experten des IuK

- ▷ **Fleiss Kappa:** Inter-Rater Reliability
- ▷ **Bewertungsrubrik:** 0-10 Punkte / Kategorie & Frage:
Relevanz, Klarheit, Beantwortbarkeit, Herausfordernd & Korrektheit vs. Umgang mit Manipulation

How to: Fleiss Kappa

- **Ziel:** Inter-Rater Reliability der Experten durch:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \text{ mit}$$

p_o beobachtete Übereinstimmung,

p_e erwartete Übereinstimmung durch Zufall,

N Anzahl der Fragen,

n Anzahl der Rater

$$p_o = \frac{\sum_{i=1}^N \sum_{j=1}^k n_{ij}^2 - N \cdot n}{N \cdot n \cdot (n - 1)}$$

$$p_e = \sum_{j=1}^k p_j^2$$

Ergebnisse & Diskussion

Quantitative Analyse 1 – Fragetypen

- **Exp 1a:** 9/168 Fragen Freitext, nur komplexer Prompt
8x OpenAI, 1x Google
- **Exp 1b:** 4/56 Fragen Freitext, 1x einfacher Prompt
(DeepSeek), 3x Google

Tabelle 1: Freitext-Scoring aus 1a und 1b.

Experiment	Cosine Similarity			Adherence Score		
	Mean	Std	Count	Mean	Std	Count
Exp1a	0.673	0.079	9	0.920	0.168	9
Exp1b	0.501	0.184	4	0.764	0.338	4

Quantitative Analyse 1a – LLMs




Abbildung 2: Verteilung nach LLM (1a).

Quantitative Analyse 1a – Input Sources






Abbildung 3: Verteilung nach Eingabequelle (1a).

Quantitative Analyse 1a – Input Sources

Cosine Similarity (-1 to 1): LLM vs Input Source (Exp 1a)
Values: Mean (Std)




Adherence Score (0 to 1): LLM vs Input Source (Exp 1a)
Values: Mean (Std)




Quantitative Analyse 1a – Prompt Types

Cosine Similarity (-1 to 1): LLM vs Prompt Type (Exp 1a)
Values: Mean (Std)



Adherence Score (0 to 1): LLM vs Prompt Type (Exp 1a)
Values: Mean (Std)



Quantitative Analyse 1b – LLMs






Abbildung 6: Verteilung nach LLM (1b).

Quantitative Analyse 1b – Prompt Types

Cosine Similarity (-1 to 1): LLM vs Prompt Type (Exp 1b)
Values: Mean (Std)



Adherence Score (0 to 1): LLM vs Prompt Type (Exp 1b)
Values: Mean (Std)



Qualitative Analyse

- Expertenbewertung ausstehend

Limitations

- **Adherence Score:** Rater-Modelle mit Reasoning
 - Temperatur nicht einstellbar, womöglich hoch/variiert
 - Wichtig für Bewertung gewesen
 - Nachteil von Reasoning? Exp. 2 Bewertung?
- **Quantitativ:** Experiment 1b schwer nachvollziehbar
 - Expertenbewertung von Bedeutung

Fazit & Ausblick

Hauptergebnisse zu RQ1 – Exp. 1a

- **Bezüglich der LLMs:**

- **CosSim:** DeepSeek R1 schwächstes, Gemini bestes
- **Adherence:** Ergebnisse nah beieinander

- **Eingabequellen:**

- **CosSim:** Script > Tanenbaum > Transcript
- **Adherence:** Quellen-übergreifend ähnlich

- **Prompt-Strategien:**

- **CosSim:** Komplexer Prompt > Einfacher Prompt
- **Adherence:** Eher andersherum

- **Kritisch:** „Welche Funktionen hat OSI-Layer n nicht?“

Hauptergebnisse zu RQ1 – Exp. 1b

- **Manipulierte Inhalte – Performance:**
 - **DeepSeek R1:** Schwächstes bei beiden Metriken
 - **CosSim:** Stets hoch, Manipulation erkannt?
 - **Adherence:** Instabil, DeepSeek und OpenAI besonders betroffen im komplexen Prompt
 - **Beide Metriken:** Einfacher Prompt > Komplexer Prompt
- **Kritisch:** „Laut dem zum ISO-OSI-Modell widersprüchlichen Text, was sind [...]?“
 - Expertenanalyse von Bedeutung

Ausblick auf Exp. 2

- **Fokus:** Bloom's Taxonomy-Alignment mit LLMs
- **Fragetypen:** Multiple-Choice & Freitextfragen
- **Vorgehen:** Deskriptives Prompting mit
 - ▷ Rollenzuweisung etc.
 - ▷ (Nicht-)Angabe von Fragetyp
 - ▷ (Nicht-)Angabe von Bloom Level
- **Evaluatoren:** Bestenfalls Experten
- **Rubrik:** Gleiche mit *Bloom's Level*

Timeline bis zur Verteidigung




Abbildung 8: GANTT-Diagramm bis zur Verteidigung.

Literaturverzeichnis I

- [Blo+23] Ariel Blobstein u. a. „Angel: A New Generation Tool for Learning Material based Questions and Answers“. In: *NeurIPS'23 Workshop on Generative AI for Education* (2023). URL: https://gaied.org/neurips2023/files/9/9_paper.pdf (besucht am 10.04.2025).
- [Elk+23] Sabina Elkins u. a. „How Useful Are Educational Questions Generated by Large Language Models?“ In: *Artificial Intelligence in Education. Posters and Late Breaking Results, Workshops and Tutorials, Industry and Innovation Tracks, Practitioners, Doctoral Consortium and Blue Sky*. Hrsg. von Ning Wang u. a. Cham: Springer Nature Switzerland, 2023, S. 536–542. ISBN: 978-3-031-36336-8. DOI: [10.1007/978-3-031-36336-8_83](https://doi.org/10.1007/978-3-031-36336-8_83).
- [HWY24] Ching Nam Hang, Chee Wei Tan und Pei-Duo Yu. „MCQGen: A Large Language Model-Driven MCQ Generator for Personalized Learning“. In: *IEEE Access* 12 (2024), S. 102261–102273. ISSN: 2169-3536. DOI: [10.1109/ACCESS.2024.3420709](https://doi.org/10.1109/ACCESS.2024.3420709). URL: <https://ieeexplore.ieee.org/document/10577164/> (besucht am 09.04.2025).

- [Hor+20] Andrea Horbach u. a. „Linguistic Appropriateness and Pedagogic Usefulness of Reading Comprehension Questions“. In: *Proceedings of the Twelfth Language Resources and Evaluation Conference*. LREC 2020. Hrsg. von Nicoletta Calzolari u. a. Marseille, France: European Language Resources Association, Mai 2020, S. 1753–1762. ISBN: 979-10-95546-34-4. URL: <https://aclanthology.org/2020.lrec-1.217/> (besucht am 12. 05. 2025).
- [Kra02] David R. Krathwohl. „A Revision of Bloom’s Taxonomy: An Overview“. In: *Theory Into Practice* 41.4 (1. Nov. 2002), S. 212–218. ISSN: 0040-5841, 1543-0421. DOI: [10.1207/s15430421tip4104_2](https://doi.org/10.1207/s15430421tip4104_2). URL: https://www.tandfonline.com/doi/full/10.1207/s15430421tip4104_2 (besucht am 24. 04. 2025).

- [ML24] Zejia Mi und Kangkang Li. „A Comparative Analysis of Different Large Language Models in Evaluating Student-Generated Questions“. In: *2024 13th International Conference on Educational and Information Technology (ICEIT)*. 2024 13th International Conference on Educational and Information Technology (ICEIT). März 2024, S. 24–29. DOI: [10.1109/ICEIT61397.2024.10540914](https://doi.org/10.1109/ICEIT61397.2024.10540914). URL: <https://ieeexplore.ieee.org/document/10540914> (besucht am 04.04.2025).
- [Nav+24] Humza Naveed u. a. *A Comprehensive Overview of Large Language Models*. 17. Okt. 2024. DOI: [10.48550/arXiv.2307.06435](https://doi.org/10.48550/arXiv.2307.06435). arXiv: [2307.06435 \[cs\]](https://arxiv.org/abs/2307.06435). URL: <http://arxiv.org/abs/2307.06435> (besucht am 06.04.2025).

Literaturverzeichnis IV

- [SCS24] Nicy Scaria, Suma Dharani Chenna und Deepak Subramani. „How Good are Modern LLMs in Generating Relevant and High-Quality Questions at Different Bloom's Skill Levels for Indian High School Social Science Curriculum?" In: *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024)*. BEA 2024. Hrsg. von Ekaterina Kochmar u. a. Mexico City, Mexico: Association for Computational Linguistics, Juni 2024, S. 1–10. URL: <https://aclanthology.org/2024.bea-1.1/> (besucht am 07.04.2025).
- [Ste+21] Tim Steuer u. a. „I Do Not Understand What I Cannot Define: Automatic Question Generation With Pedagogically-Driven Content Selection". In: *ArXiv* (8. Okt. 2021). URL: <https://www.semanticscholar.org/paper/I-Do-Not-Understand-What-I-Cannot-Define%3A-Automatic-Steuer-Filighera/a0fd69c2540158fe79ff8cdba3d36a71e737211a> (besucht am 04.04.2025).

- [ZWC25] Qingfeng Zhuge, Han Wang und Xuyang Chen. „TwinStar: A Novel Design for Enhanced Test Question Generation Using Dual-LLM Engine“. In: *Applied Sciences* 15.6 (Jan. 2025). Number: 6 Publisher: Multidisciplinary Digital Publishing Institute, S. 3055. ISSN: 2076-3417. DOI: [10.3390/app15063055](https://doi.org/10.3390/app15063055). URL: <https://www.mdpi.com/2076-3417/15/6/3055> (besucht am 09.04.2025).

Vielen Dank für Ihre
Aufmerksamkeit!