

LLMs in der Fragengenerierung

– Endverteidigung –

Malte Grube – B.Sc. Informatik (2021)¹

¹Betreuer: *Prof. Dr. rer.nat. Clemens H. Cap*
Jun.-Prof.in Dr.in Charlott Rubach

1. September 2025

1. Einführung & Problem

2. Exp. 1 – Inhaltstreue

3. Exp. 2 – Bloom-Analyse

4. Schlusswort

Einführung & Problem

Motivation & Problemstellung I

- **Motivation:**

- ▷ Aktives Lernen → gezielte Fragen
- ▷ Anspruchsvolle Fragen → zeitaufwendig [Ste+21]

- **Potenzial von LLMs:** Automatisierte Fragen-generierung → bessere Lehrmaterialien-Erstellung + Lernerfahrungen möglich [Nav+24]

- Um **aktives Lernen** zu fördern und nicht nur Texte zu lesen, sind gezielte **Kontrollfragen** sinnvoll.
- Eine Menge an **anspruchsvollen Fragen** zu erstellen ist jedoch **zeitaufwendig**.

Motivation & Problemstellung II

- **Problemstellung:** Qualität oft unklar → mangelnde systematische Evaluation über linguistische Tests hinaus [**Hor+20**]
 - ▷ Selten pädagogische Bewertung [**ZWC25**; **Blo+23**; **SCS24**]
 - ▷ Mangelnde Performance bei höheren kognitiven Levels [**Elk+23**; **SCS24**]
 - ▷ Relevanz ≠ Inhaltstreue [**Elk+23**; **HWY24**; **ML24**]
- **Forschungslücken:**
 - ▷ Untersuchung der Inhaltstreue von LLMs
 - ▷ Einhalten kognitiver Anforderungsniveaus

Problemstellung:

- P1: man muss auch **pädagogische Eignung** bewerten, aber
- P1.1: manchmal nur **linguistische Metriken** genutzt, oder eben Expertenbewertung **ohne Bloom**
- P1.2: zu **alte** Modelle...
- P1.3: **Korrektheit** von Fragen **elementar** in Bildung; Inhaltstreue oft nur als **Future Work**

Forschungsfragen

- **RQ1:** Zu welchem Grad **halten sich LLMs** an den Inhalt verschiedener bereitgestellter **Lehrtexte** bei der Generierung von Fragen?
- **RQ2:** Wie beeinflusst die **Beziehung** zwischen verschiedenen Frageformaten und den Levels der Bloom's Taxonomie die **pädagogische Wirksamkeit** von LLM-generierten Fragen?

Bloom's revised Taxonomy

- **Pädagogische Relevanz:** Systematische Bewertung kognitiver Anforderungen von Fragen [Kra02]




Abbildung 1: Kognitive Bloom-Hierarchie.

- **Remembering:** Abruf von Faktenwissen – *wiedergeben, nennen*
- **Understanding:** Bedeutung von Anweisungen erkennen – *erklären, beschreiben, zusammenfassen*
- **Applying:** Wissen in gegebenen Situationen anwenden – *anwenden, benutzen, durchführen*
- **Analyzing:** Material in Komponenten zerlegen – *untersuchen, vergleichen, kategorisieren*
- **Evaluating:** Urteile basierend auf Kriterien fällen – *bewerten, beurteilen, kritisieren*
- **Creating:** Elemente zu Ganzem zusammenfügen – *entwerfen, planen, entwickeln*

Herausforderungen der Literatur

- **Veraltete Modelle** – Kein Reasoning
- **Halluzinationen** – Falsche Ausgaben
- **Inhaltstreue** – Forschung nötig
- **Quantitative Metriken** – Linguistischer Fokus
- **Expertenbewertung** – Selten, da aufwendig
- **Bloom's Taxonomy** – Level Alignment & hohe kognitive Levels

- P1: basiert auf User Prompt ⇒ Anforderungen **brainstormen**, zuvor **nicht genutzt**, sondern **outdated** Models (GPT-4)
- P2: Kann man minimieren durch **Kontext**
- P3: Inhaltstreue eher **Nebensache**, mehr **Bloom** Fokus, **linguistische** Metriken
- P4: Problematisch, da grundlegend **linguistisch** ⇒ **Expertenbewertung** notwendig bei AQG
- P5: **Selten** ausgiebig performt, weil aufwendig
- P6: Hohe Levels **misslingen** in RW; auch **nicht immer Bloom** benutzt (dann eher schlecht)

How to: Fleiss' Kappa

- **Ziel:** Inter-Rater Reliability der Experten durch:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \text{ mit}$$

p_o beobachtete Übereinstimmung,
 p_e erwartete Übereinstimmung durch Zufall,
 N Anzahl der Fragen,
 n Anzahl der Rater

$$p_o = \frac{\sum_{i=1}^N \sum_{j=1}^k n_{ij}^2 - N \cdot n}{N \cdot n \cdot (n - 1)}$$

$$p_e = \sum_{j=1}^k p_j^2$$

- n_{ij} **#Rater**, die für Frage i das Rating j abgegeben haben
- k Menge der **Auswahlmöglichkeiten** 0,2,4,6,8,10
- p_e wird jede **Zählung quadriert**, die werden **summiert** (wie viele Rater haben in Rating j Zustimmung gegeben)

Beispiel: Fleiss' Kappa

Q	R1	R2	R3
1	Y	Y	Y
2	N	Y	N

Q	Y	N
1	3	0
2	1	2
Σ	4	2

6 Ratings, somit: $\frac{4}{6}$ und $\frac{2}{6}$

$$\rightsquigarrow p_e = \left(\frac{4}{6}\right)^2 + \left(\frac{2}{6}\right)^2 = \underline{0.55}$$

$N = 2$ Fragen, $n = 3$ Raters:

$$p_o = \frac{3^2 + 0^2 + 1^2 + 2^2 - 2 \cdot 3}{2 \cdot 3 \cdot (3 - 1)} = \underline{0.66}$$

Einsetzen in κ -Gleichung:

$$\kappa = \frac{0.66 - 0.55}{1 - 0.55} = \underline{0.25}$$

Exp. 1 – Inhaltstreue

Experimentelles Design I

- **Ziel:** Bewertung der Inhaltstreue LLM-generierter Fragen
- **Materialien:** 3 Quellen – ISO-OSI-Modell
 - ▷ Script – „Referenzarchitekturen“ (DE)
 - ▷ Transcript – Audio-zu-Text (DE)
 - ▷ Textbook – „Computer Networks“ (EN)
- **Exp 1a:** Originaltexte
- **Exp 1b:** Manipuliertes Script

Experimentelles Design II

- 4 Large Language Models:
 - ▷ **DeepSeek:** R1 (Jan 2025)
 - ▷ **Anthropic:** Claude 3.7 Sonnet (Feb 2025)
 - ▷ **Google:** Gemini 2.5 Flash (Mar 2025)
 - ▷ **OpenAI:** o3 (Apr 2025)
 - 2 Prompt-Strategien:
 - ▷ **Einfach:** Weniger Anweisungen, keine Strukturierung, aber Formatvorlage + Material
 - ▷ **Komplex:** Rollenzuweisung, detaillierte Anweisungen, fordert nicht-triviales und kritisches Denken, Struktur durch Docstrings, Formatvorlage + Material
- P2.1: **Generiere** zum ISO-OSI Modell; korrekte Antwort **klar gekennzeichnet** sein; **keine Strukturierung**; Frage **klar & präzise**, soll **kein weiterer Text** generiert werden
 - P2.2: **Experte** in Generieren von kognitiv anspruchsvollen Fragen; **Untersuchen** des Texts & **Erfassen** des Wichtigen; nur **Fließtext**

Datenerhebung & Durchführung

- **Python:** Automatisierte API-Ansteuerungen
- **Website-Prompting:** DeepSeek R1
- **Material:** Layer-weise Aufteilung
- **#Fragen:**

$4 \text{ LLMs} \times 3 \text{ Inputs} \times 7 \text{ Layers} \times 2 \text{ Prompts} = 168 \text{ Fragen}$

$4 \text{ LLMs} \times 1 \text{ Input} \times 7 \text{ Layers} \times 2 \text{ Prompts} = 56 \text{ Fragen}$

Evaluations-Methodik I

- **Quantitativ:**

- ▷ **Semantic Similarity:** Generierte Frage vs. Originaltext
→ Embedding-Modell & Cosine Similarity

$$\cos(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|}$$


- ▷ **Adherence Score:** o3 & Claude 3.7 Sonnet Prompting

- **Qualitativ:** Prof. Cap + 4 Experten des IuK

- ▷ **Fleiss' Kappa:** Inter-Rater Reliability
- ▷ **Bewertungsrubrik:** 0-10 Punkte / Kategorie & Frage:
*Relevance, Clarity, Answerability, Challenging, Value,
Language & Correctness/Manipulation Handling*

Quantitative Analyse – Exp. 1a

Cosine Similarity (-1 to 1): LLM vs Prompt Type (Exp 1a)
Values: Mean (Std)



Adherence Score (0 to 1): LLM vs Prompt Type (Exp 1a)
Values: Mean (Std)





Abbildung 2: Heatmaps LLMs vs. Prompt-Typen (1a).

Quantitative Analyse – Exp. 1b

Cosine Similarity (-1 to 1): LLM vs Prompt Type (Exp 1b)
Values: Mean (Std)



Adherence Score (0 to 1): LLM vs Prompt Type (Exp 1b)
Values: Mean (Std)




Abbildung 3: Heatmaps LLMs vs. Prompt-Typen (1b).

Qualitative Analyse – Exp. 1a





Abbildung 4: Correctness Heatmaps – Input Sources:
links Supervisor, rechts Staff.

Qualitative Analyse – Exp. 1a

Correctness Score (LLM vs Prompt Type)
Values: Mean (Std) | Scale: 0-10 points



Correctness Score (LLM vs Prompt Type)
Values: Mean (Std) | Scale: 0-10 points




Abbildung 5: Correctness Heatmaps – Prompt Types:
links Supervisor, rechts Staff.

Qualitative Analyse – Exp. 1a

Tabelle 1: Inter-Rater Agreement Analyse (Exp1a).

Links: Staff. Rechts: Kombiniert.

Kriterium	Fleiss' $\kappa \uparrow$	Std	#Raters	Fleiss' $\kappa \uparrow$	Std	#Raters
Relevance	-0.085	1.92	4	-0.046	1.88	5
Clarity	0.034	2.72	4	0.077	2.68	5
Answerability	0.015	2.84	4	0.054	2.77	5
Challenging	0.011	2.35	4	0.014	2.61	5
Value	-0.010	3.23	4	0.012	3.34	5
Language	0.001	2.59	4	0.043	2.53	5
Correctness	-0.052	2.67	4	-0.022	2.56	5

Qualitative Analyse – Exp. 1b

Tabelle 2: Manipulation Handling Analyse via LLM & Prompt Type.
Links: Supervisor. Rechts: Staff.

LLM	Prompt Type	Supervisor Scores			Staff Scores		
		Mean	Std	Median	Mean	Std	Median
Anthropic	Common	0.0	0.0	0.0	2.50	4.63	0.0
	Complex	2.5	3.54	2.5	7.25	2.55	8.0
DeepSeek	Common	2.5	3.54	2.5	3.38	4.37	1.5
	Complex	2.5	3.54	2.5	5.12	4.64	5.5
Google	Common	0.0	0.0	0.0	3.50	4.66	0.5
	Complex	2.5	3.54	2.5	7.88	3.00	8.5
OpenAI	Common	0.0	0.0	0.0	2.50	4.63	0.0
	Complex	0.0	—	0.0	5.00	3.93	4.0

Qualitative Analyse – Exp. 1b

Tabelle 3: Inter-Rater Agreement Analyse (Exp1b).

Manipulation Handling	Fleiss' $\kappa \uparrow$	Std	#Items	#Raters
Nur Staff	0.014	4.31	16	4
Mit Supervisor kombiniert	0.036	4.21	15	5

Exp. 2 – Bloom-Analyse

Experimentelles Design I

- **Ziel:** Auswertung Bloom-Level / Alignment
- **Materialien:** Alle ISO-OSI Script Layer
- **Fragetypen:** Multiple-Choice & Freitextfragen
- **Prompting:** Rollenzuweisung, klare Formatvorgaben, Angabe von Fragetyp, Bloom-Level, oder beidem:

4 LLMs × 2 Fragetypen × 6 Runs = 48 Fragen

4 LLMs × 6 Levels = 24 Fragen

4 LLMs × 2 Fragetypen × 6 Levels = 48 Fragen

Evaluations-Methodik

- **Qualitativ:** Ausschließlich Nutzen der Rubrik mit *Bloom's Level* statt *Correctness*
- **Umsetzung:** 3 Studenten von Prof. Rubach & Inter-Rater Agreement (Fleiss' Kappa)

Qualitative Analyse – Exp. 2

Tabelle 4: Bloom Scores via LLM und Sub-Experiment.

LLM	Mean			Std			Median		
	Exp2a	Exp2b	Exp2c	Exp2a	Exp2b	Exp2c	Exp2a	Exp2b	Exp2c
Anthropic	4.96	8.33	8.75	2.57	4.08	2.26	7.0	10.0	10.0
DeepSeek	2.83	8.33	8.75	1.50	4.08	2.26	3.0	10.0	10.0
Google	4.54	8.33	9.58	2.53	4.08	1.44	3.0	10.0	10.0
OpenAI	3.67	10.00	7.50	2.78	0.00	3.99	3.0	10.0	10.0

Qualitative Analyse – Exp. 2

Tabelle 5: Vergleich von Bloom Scores zwischen Fragetyp & Sub-Experiment (2a und 2c).

Fragetyp	Mean		Std		Median	
	Exp2a	Exp2c	Exp2a	Exp2c	Exp2a	Exp2c
Multiple-Choice	2.42	7.92	1.23	3.27	2.25	10.0
Open-Ended	5.58	9.38	2.38	1.69	7.00	10.0

Qualitative Analyse – Exp. 2

Tabelle 6: Inter-Rater Agreement Analyse (Exp2).

Kriterium	Fleiss' $\kappa \uparrow$	Std	#Items	#Raters
Relevance	0.056	1.71	40	3
Clarity	-0.058	1.61	40	3
Answerability	0.179	1.90	39	3
Challenging	0.270	2.52	40	3
Value	-0.256	1.72	40	3
Language	0.016	1.95	40	3
Bloom Rating	0.397	1.67	40	3

Schlusswort

Hauptergebnisse zu RQ1 I

- **LLMs erstellen inhaltsgetreue Fragen** unter bestimmten Bedingungen
- **Common Prompt > Complex** meistens
- Script vs. Transcript oft eng beieinander, wobei **Staff**: Script vs. **Supervisor**: Transcript
- OpenAI & DeepSeek **konsistenter**

- P1: Adherence Score ⇒ die Fragen **inhaltlich gut**
Sentence Transformer **ungeeignet** für langes/strukturiertes
- P2: Sowohl bei **quantitativ** als auch **qualitativ**; Complex nur besser in **Challenging** mit Einbußen
Überladen/wenig präziser Prompt ⇒ – besseres
- P3: **Transcript Cap** bestes in Clarity, Answerability und Correctness, beide Gruppen **Challenging** geringstes **Script Staff** ausgeglichen mit höchstem **Total Score ebenso** bei Script, oft das effektivere Material
- P4: Anthropic & Google **variabler**... teils sprachlich **komplex** oder mit **fehlerhaften / erfundenen** Optionen

Hauptergebnisse zu RQ1 II

- „Basierend auf dem gegebenen Text“
⇒ oft bei DeepSeek & Google
 - **Teilweise Erkennung** von Manipulationen:
OpenAI & DeepSeek beim komplexen Prompt
 - **Kleine Stichprobe** (16/56) und **geringe IRR**
⇒ Inkonsistente Trends quantitativ & qualitativ
 - **Bloom's Taxonomy** essenziell für gute +
Anforderungs-gesteuerte Fragen
- P3: Deswegen Google & Anthropic hier **besser**
Rubrik & Pflichten der Bewerter müssen **refined** werden
 - ⇒ klappt dann gut, wenn man **klare Anweisungen** gibt +
strukturiertes, präzises **Material**
 - Fragen **wenig Challenging** (auch nicht so sehr bei Complex
Prompt) ⇒ Wichtigkeit von **Bloom's Taxonomy** da

Hauptergebnisse zu RQ2 I

- Bloom-Level-Spezifikation ⇒ **hohe Adhärenz**
- Ohne Spezifikation ⇒ **niedrigere Levels** (Levels 2-3)
- **Open-Ended** ⇒ alle Levels + **besseres Alignment**
- MCQs für **niedrige Levels** ⇒ kombinieren

Hauptergebnisse zu RQ2 II

- *Type Only*: **Anthropic & Google** > DeepSeek & OpenAI
 - *Bloom Only*: **OpenAI** am besten
 - *Type+Bloom*: **Google** am besten
 - Hohe IRR bei *Bloom's Level*
 - **Pädagogisch qualitativ**: Bloom-Vorgaben + passende Fragetypen + durchdachtes Prompting + klare Lernziele + moderne LLMs
- P4: Answerability 0.179, Challenging 0.270; aber andere gegen 0 oder Value -0.256
 - Braucht besseres **Rubrik-Design** (vor allem wegen Value) + **klarere Anker**

Limitations/Future Work I

- Cosine Similarity **ungeeignet**
- Besseres **Multi-LLM-Judging** für Inhaltstreue
- **Größere Stichprobe** bei Manipulation
- Klare **Ankerbeschreibungen** & **Lernziele** integrieren
- #Raters ↑ reicht nicht aus ⇒ **bessere Rubrik**

- P1: **Kein Unterschied** in Inhaltstreue zwischen Fragen mit Source Material und ohne...
- P2: Statt zwei Modelle und dann **Mean**, da geht mehr
- P3: **Konsistente Auswertung**, da 16/56 zu wenig war
- P4: 0-10 Skala doch **zu ungenau** trotz Anker

Limitations/Future Work II

- Wenn **MCQs** $\Rightarrow$ mehrstufige Pipeline
- **Reasoning vs. Non-Reasoning** Modelle vergleichen
- **Halluzinationen** reduzieren
- Thesis-Grundlage: Umsetzung eines **robusten & pädagogisch sinnvollen** AQG-Frameworks

- P1: Frage, richtige, falsche Optionen **separat** generieren
- P2: Bzw. mit und ohne den **Reasoning** Prozess
- Dazu: Reasoning **schwer auswertbar**, da zunehmend proprietär; **Summaries** wenn überhaupt verfügbar
- Sowohl bei **Modellen** als auch durch **Prompting**

- [Blo+23] Ariel Blobstein u. a. „Angel: A New Generation Tool for Learning Material based Questions and Answers“. In: *NeurIPS'23 Workshop on Generative AI for Education* (2023). URL: https://gaied.org/neurips2023/files/9/9_paper.pdf (besucht am 10.04.2025).
- [Elk+23] Sabina Elkins u. a. „How Useful Are Educational Questions Generated by Large Language Models?“ In: *Artificial Intelligence in Education. Posters and Late Breaking Results, Workshops and Tutorials, Industry and Innovation Tracks, Practitioners, Doctoral Consortium and Blue Sky*. Hrsg. von Ning Wang u. a. Cham: Springer Nature Switzerland, 2023, S. 536–542. ISBN: 978-3-031-36336-8. DOI: [10.1007/978-3-031-36336-8_83](https://doi.org/10.1007/978-3-031-36336-8_83).
- [HWY24] Ching Nam Hang, Chee Wei Tan und Pei-Duo Yu. „MCQGen: A Large Language Model-Driven MCQ Generator for Personalized Learning“. In: *IEEE Access* 12 (2024), S. 102261–102273. ISSN: 2169-3536. DOI: [10.1109/ACCESS.2024.3420709](https://doi.org/10.1109/ACCESS.2024.3420709). URL: <https://ieeexplore.ieee.org/document/10577164/> (besucht am 09.04.2025).

- [Hor+20] Andrea Horbach u. a. „Linguistic Appropriateness and Pedagogic Usefulness of Reading Comprehension Questions“. In: *Proceedings of the Twelfth Language Resources and Evaluation Conference*. LREC 2020. Hrsg. von Nicoletta Calzolari u. a. Marseille, France: European Language Resources Association, Mai 2020, S. 1753–1762. ISBN: 979-10-95546-34-4. URL: <https://aclanthology.org/2020.lrec-1.217/> (besucht am 12. 05. 2025).
- [Kra02] David R. Krathwohl. „A Revision of Bloom’s Taxonomy: An Overview“. In: *Theory Into Practice* 41.4 (1. Nov. 2002), S. 212–218. ISSN: 0040-5841, 1543-0421. DOI: [10.1207/s15430421tip4104_2](https://doi.org/10.1207/s15430421tip4104_2). URL: https://www.tandfonline.com/doi/full/10.1207/s15430421tip4104_2 (besucht am 24. 04. 2025).

- [ML24] Zejia Mi und Kangkang Li. „A Comparative Analysis of Different Large Language Models in Evaluating Student-Generated Questions“. In: *2024 13th International Conference on Educational and Information Technology (ICEIT)*. 2024 13th International Conference on Educational and Information Technology (ICEIT). März 2024, S. 24–29. DOI: [10.1109/ICEIT61397.2024.10540914](https://doi.org/10.1109/ICEIT61397.2024.10540914). URL: <https://ieeexplore.ieee.org/document/10540914> (besucht am 04.04.2025).
- [Nav+24] Humza Naveed u. a. *A Comprehensive Overview of Large Language Models*. 17. Okt. 2024. DOI: [10.48550/arXiv.2307.06435](https://doi.org/10.48550/arXiv.2307.06435). arXiv: [2307.06435 \[cs\]](https://arxiv.org/abs/2307.06435). URL: <http://arxiv.org/abs/2307.06435> (besucht am 06.04.2025).

- [SCS24] Nicy Scaria, Suma Dharani Chenna und Deepak Subramani. „How Good are Modern LLMs in Generating Relevant and High-Quality Questions at Different Bloom's Skill Levels for Indian High School Social Science Curriculum?“ In: *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024)*. BEA 2024. Hrsg. von Ekaterina Kochmar u. a. Mexico City, Mexico: Association for Computational Linguistics, Juni 2024, S. 1–10. URL: <https://aclanthology.org/2024.bea-1.1/> (besucht am 07.04.2025).
- [Ste+21] Tim Steuer u. a. „I Do Not Understand What I Cannot Define: Automatic Question Generation With Pedagogically-Driven Content Selection“. In: *ArXiv* (8. Okt. 2021). URL: <https://www.semanticscholar.org/paper/I-Do-Not-Understand-What-I-Cannot-Define%3A-Automatic-Steuer-Filighera/a0fd69c2540158fe79ff8cdba3d36a71e737211a> (besucht am 04.04.2025).

- [ZWC25] Qingfeng Zhuge, Han Wang und Xuyang Chen. „TwinStar: A Novel Design for Enhanced Test Question Generation Using Dual-LLM Engine“. In: *Applied Sciences* 15.6 (Jan. 2025). Number: 6 Publisher: Multidisciplinary Digital Publishing Institute, S. 3055. ISSN: 2076-3417. DOI: [10.3390/app15063055](https://doi.org/10.3390/app15063055). URL: <https://www.mdpi.com/2076-3417/15/6/3055> (besucht am 09.04.2025).

Vielen Dank für Ihre
Aufmerksamkeit!